

Hybrid MPPT with Deterministic PSO and Super-Twisting: Minimum-Time Tracking under Complex Partial Shading

Abstract

Introduction

La búsqueda de soluciones energéticas sostenibles ha impulsado significativamente el desarrollo de sistemas fotovoltaicos (FV), consolidados como un pilar clave en la transformación del panorama energético global. Estos sistemas convierten la radiación solar en electricidad, su eficiencia depende críticamente de operar en el punto de máxima potencia (MPP), donde se extrae la máxima energía disponible; lograr este objetivo es esencial para maximizar la rentabilidad y estabilidad de las instalaciones FV. Bajo condiciones de sombreado parcial (PSC), causado por obstrucciones como nubes, árboles o estructuras, la curva característica corriente-voltaje (I-V) presenta múltiples máximos locales, complicando la identificación del punto de máxima potencia global (GMPP) [1].

Los métodos tradicionales de seguimiento del punto de máxima potencia (MPPT), como Perturbación y Observación (P&O) [2] y Conductancia Incremental (INC) [3], operan midiendo la potencia de salida del sistema fotovoltaico (FV) y modulando el ciclo de trabajo del convertidor CC-CC. Mediante este ajuste, modifican la impedancia de carga vista por los paneles FV para alcanzar el MPP. P&O utiliza perturbaciones de voltaje con dirección determinada por el signo del cambio de potencia, lo que induce oscilaciones en el MPP. INC, en cambio, evalúa la relación dP/dV mediante conductancias para detener perturbaciones al alcanzar el MPP, mejorando la estabilidad y respuesta dinámica. Aunque son computacionalmente ligeros, presentan limitaciones críticas: oscilan persistentemente alrededor del MPP, exhiben lenta convergencia en condiciones dinámicas [4] y, crucialmente, no garantizan encontrar el GMPP bajo sombreado parcial [2,5]. Estas fallas reducen la eficiencia energética y aumentan las pérdidas en escenarios reales con irradiancia variable.

Para superar estas limitaciones, se han propuesto enfoques predictivos que estiman el voltaje o corriente en el MPP mediante regresores entrenados con variables operativas (irradiancia global, temperatura, corrientes y voltajes del sistema fotovoltaico). Modelos de regresión como los lineales [6], las máquinas de soporte vectorial [7], Gaussian Regression Process [8], Redes Neuronales Artificiales (incluyendo arquitecturas de Perceptrón Multicapa [9–11], Redes Recurrentes [12] y Redes de Base Radial [13,14]), han demostrado alta precisión en predecir el voltaje en el cual se da el MPP sin sombras. La implementación de modelos regresores para el seguimiento del MPP en condiciones de sombreado parcial enfrenta una barrera fundamental: la impredecibilidad en el número, ubicación y extensión de las sombras sobre los módulos requeriría sensores de irradiancia individualizados por cada zona afectada, un requisito inviable en aplicaciones prácticas [15]. Esta incertidumbre inherente hace prácticamente imposible desarrollar modelos regresores robustos para MPPT en estos escenarios. Además, la generación de conjuntos de datos suficientemente amplios que cubran todas las posibles combinaciones de sombreado y condiciones operativas resulta prohibitiva para poder entrenar correctamente dichos modelos. Estas limitaciones motivan el desarrollo de alternativas que prescindan de mediciones distribuidas de irradiancia.

Como alternativa a la predicción del punto del MPP, se han utilizado algoritmos metaheurísticos que realizan una búsqueda directa de la solución operativa óptima,

expresada como ciclo de trabajo del convertidor, corriente o voltaje del FV. Estos métodos evitan la dependencia de modelos predictivos y localizan el máximo global (GMPP) bajo sombreado parcial mediante reglas de exploración inteligente. Metaheurísticas como la Optimización por Enjambre de Partículas (PSO) [1, 16], Algoritmos Genéticos (GA) [17], Cuckoo Search [18], entre otras, ajustan dinámicamente estas variables de control para tratar de converger al GMPP sin utilizar información de sensores de irradiancia o temperatura [19]. En general, los algoritmos metaheurísticos se basan en soluciones iniciales aleatorias y búsquedas estocásticas, lo que genera tiempos de convergencia no deterministas y perturbaciones abruptas en la potencia durante la exploración.

Las arquitecturas híbridas para el MPPT constituyen un enfoque avanzado que integra metaheurísticas de búsqueda global con técnicas de control para implementar físicamente las soluciones operativas. En este esquema, algoritmos como PSO, GA, Cuckoo search o cualquier otra metaheurística, exploran el espacio de soluciones para identificar la región del punto de máxima potencia global (GMPP), generando referencias de ciclos de trabajo, corriente o voltaje en el que el FV debe operar, hasta encontrar la referencia óptima. Dado que estas referencias son setpoints teóricos, un controlador lineal o no lineal (Proporcional Integral PI [20], modos deslizantes (SMC) [21], finite control set Model Predictive Control [22], etc.), se encarga de alcanzar y mantener dichos valores en el sistema PV, realizando el ajuste fino con robustez frente a perturbaciones. Esta arquitectura dual es intrínsecamente híbrida: aprovecha la exploración global de las metaheurísticas y la estabilidad de los controladores para seguir dinámicamente las referencias. La cooperación estratégica entre ambos módulos: búsqueda de referencias y control de ejecución, permite alcanzar el GMPP con precisión inalcanzable por técnicas aisladas [23].

El objetivo central de esta investigación es determinar si una nueva arquitectura híbrida de control compuesta por: un algoritmo metaheurístico con generación determinista de soluciones (en lugar de estocástica) que opera mediante referencias de corriente, y un controlador super-twisting acoplado, puede alcanzar un tiempo de convergencia más rápido y consistente, minimizando oscilaciones para localizar el GMPP bajo sombreado parcial, superando así a enfoques estocásticos. Para validar este objetivo, se adaptó el algoritmo Simplified Accelerated PSO (SAPSO) [24] variante determinista del PSO que elimina aleatoriedad mediante reglas de búsqueda de voltajes factibles en inicialización y evolución. Nuestra adaptación modifica el algoritmo para operar con referencias de corriente, suavizando la convergencia hacia el óptimo. La versión resultante la denominamos Modified SAPSO (MSAPSO).

Además, se realizó un análisis del impacto del tiempo de espera entre iteraciones, parámetro crítico que permite al controlador estabilizarse en cada referencia generada (ciclo de trabajo, corriente o voltaje). Un intervalo demasiado corto impide la estabilización completa de la potencia, mientras que uno excesivamente largo compromete la capacidad de seguimiento dinámico del GMPP bajo sombreado variable. La optimización de este parámetro validada mediante simulaciones demuestra ser clave para maximizar la precisión del seguimiento sin degradar la velocidad de convergencia del sistema.

Modelado del sistema fotovoltaico

El modelado de una celda fotovoltaica (PV) es fundamental para comprender y predecir su comportamiento bajo diferentes condiciones ambientales, como la irradiancia y la temperatura. Este proceso permite simular con precisión las características eléctricas de la celda, lo cual es esencial para el diseño y la optimización de sistemas fotovoltaicos. Una celda PV genera electricidad mediante el efecto fotoeléctrico, y para lograr una

salida de potencia eficiente, las celdas se conectan en configuraciones en serie y paralelo para formar un módulo PV. Dependiendo de su complejidad, una celda PV puede representarse mediante varios modelos de circuito equivalente, siendo el modelo de un solo diodo uno de los más utilizados debido a su simplicidad y precisión razonable.

El circuito equivalente de una celda PV mostrado en la Fig. 1, consta de una fuente de corriente I_{ph} , que representa la foto corriente generada y es igual a la corriente de cortocircuito I_{sc} dependiendo de la irradiancia solar (I_r); un diodo con una corriente de saturación inversa (I_d); una resistencia en paralelo (R_{sh}), que representa las pérdidas por fugas; y una resistencia en serie (R_s), que representa las pérdidas óhmicas internas [25].




Figure 1. Circuito equivalente de una celda PV

La corriente de salida del módulo PV I_{pv} se puede describir mediante la Ec. (1), donde se asume que $R_s \ll R_{sh}$ [26],

$$I_{pv} = N_p I_{ph} - N_p I_o \left[\exp \left(\frac{q \left(\frac{V_{pv}}{N_s} + \frac{R_s I_{pv}}{N_p} \right)}{K T_c A} \right) - 1 \right] \quad (1)$$

Donde I_{pv} es la corriente de salida del módulo, I_{ph} es la corriente foto-generada de cada celda, V_{pv} es el voltaje de salida del módulo, N_s es el número de celdas conectadas en serie, N_p es el número de celdas conectadas en paralelo, q es la carga del electrón (1.602×10^{-19} C), K es la constante de Boltzmann (1.381×10^{-23} J/K), T_c es la temperatura del módulo en grados Celsius, I_o es la corriente de saturación inversa del diodo, y A es el factor de idealidad del diodo.

Sustituyendo en la Ec. (1) los parámetros de un módulo PV específico, es posible generar sus curvas I_{pv} - V_{pv} y P_{pv} - V_{pv} (para más detalles, ver [27]). A partir de estas curvas, se puede determinar el MPP (punto de máxima potencia), es decir, los valores de V_{pv} o I_{pv} que deben estar presentes en los terminales del módulo PV para que se transfiera la máxima potencia a la carga.

Si la magnitud de V_{pv} se modula, la magnitud de I_{pv} se ajusta de acuerdo con la Ec. (1), y viceversa. Es decir, si se modula la magnitud de I_{pv} , la magnitud de V_{pv} se ajusta automáticamente. Para modular las señales V_{pv} o I_{pv} , se necesita una impedancia variable y controlable entre el módulo PV y la carga. Los convertidores Buck y Boost DC-DC han sido los circuitos más utilizados para este propósito. El primero reduce el voltaje e incrementa la corriente entregada a la carga; el segundo incrementa el voltaje y reduce la corriente suministrada a la carga. Ambos convertidores DC-DC tienen alta eficiencia, de modo que la mayor parte de la potencia extraída del módulo PV puede ser entregada a la carga [28]. El convertidor Boost tiene eficiencias de potencia que van del 90% al 100% [29].

En este trabajo, se utiliza un convertidor Boost DC-DC para determinar numéricamente el MPP de un módulo PV Renesola JC250[®] (sus parámetros se enumeran en la Tabla 1). En la Fig. 2 se muestra el PV, el convertidor Boost y la arquitectura híbrida propuesta. El convertidor Boost está conectado a una carga resistiva, como se muestra en la Fig. 3, donde V_{pv} es el voltaje de entrada y V_o es el voltaje de salida. Se asume que la corriente del inductor es igual a la corriente del sistema PV I_{pv} .

Table 1. Especificaciones del Panel Fotovoltaico Renesola JC250[®]

Parámetros	Valor
I_r	1000 W/m^2
I_o	$1.9164 \times 10^{-9} \text{ A}$
R_s	0.29838Ω
N_s	60 cells
I_m	8.21 A
V_m	30.1 V




Figure 2. Partes del Sistema Fotovoltaico




Figure 3. Topología del convertidor Boost

Los componentes R , L , C_e , C_s , son la carga del convertidor, la inductancia, la capacitancia de entrada y la capacitancia de salida, respectivamente. La dinámica del convertidor se describe mediante un modelo que combina las ecuaciones resultantes de la activación y desactivación del interruptor u (entrada de control). Se asume que todos los componentes son ideales (por ejemplo, cuando $u = 1$, el MOSFET tiene una

resistencia cero entre sus terminales drenado y fuente cuando está cerrado e infinita cuando está abierto, por lo tanto, no disipa potencia). El modelo se describe en [30]:

$$\frac{dI_{pv}}{dt} = \frac{V_{pv}}{L} - \frac{(1-u)V_o}{L} \quad (2)$$

$$\frac{dV_o}{dt} = \frac{(1-u)I_{pv}}{C_s} - \frac{V_o}{RC_s} \quad (3)$$

El modelo puede representarse como:

$$\begin{aligned} \dot{x} &= f(x) + g(x)u \\ y &= Cx \end{aligned}$$

donde

$$x = [x_1 \ x_2]^T = [I_{pv} \ V_o]^T, \ u \in [0, 1], \text{ and } C = [0 \ 1].$$

Control por modos deslizantes de segundo orden Supertwisting

El algoritmo SuperTwisting (ST-SMC) representa una clase particular de control por modos deslizantes de segundo orden (SMC) caracterizado por su capacidad de estabilizar sistemas con incertidumbres sin requerir información sobre la derivada temporal de las variables deslizantes [31].

Este método ha demostrado eficacia en aplicaciones de electrónica de potencia, particularmente en convertidores DC-DC, debido a su robustez ante perturbaciones y variaciones paramétricas [32].

El ST-SMC requiere dos pasos:

- Diseño de una superficie deslizante s : Esta superficie se diseña de manera que, cuando $s = 0$, el convertidor DC-DC alcance el comportamiento deseado.
- Diseño de una ley de control: La ley de control debe garantizar que $s = 0$ de forma indefinida.

El ST-SMC combina un controlador de conmutación u_{st} con un controlador equivalente u_{eq} , es decir,

$$u = u_{st} + u_{eq} \quad (4)$$

La estrategia de conmutación es responsable de llevar el estado del sistema hacia la superficie deslizante utilizando la acción de control disponible. Una vez que la trayectoria del estado alcanza la superficie deslizante, el controlador equivalente se encarga de mantenerla evolucionando indefinidamente sobre esta superficie.

En nuestro caso, el objetivo del control es dirigir I_{pv} hacia un valor de corriente de referencia propuesta por nuestro algoritmo metaheurístico I_{MSAPSO} . Una superficie deslizante puede definirse como en [33] para abordar el problema del MPPT:

$$s = I_{pv} - I_{MSAPSO} \quad (5)$$

Esta superficie es simple y efectiva, ya que al proporcionar una referencia de corriente I_{MSAPSO} , logra mantener la potencia constante en el sistema sin generar chattering. Esto asegura una operación estable y eficiente, ideal para sistemas fotovoltaicos bajo condiciones de variabilidad e incertidumbre.

El control equivalente u_{eq} se propone como [34]:

$$u_{eq} = 1 - \frac{V_{pv}}{V_o} \quad (6)$$

donde V_o es el voltaje de salida del sistema. La entrada conmutada u_{st} se obtiene por medio de [35]:

$$u_{st} = -\lambda |s_i|^{\frac{1}{2}} \text{sign}(s_i) - \Upsilon \int_0^t \text{sign}(s_i(d\tau)) d\tau \quad (7)$$

Donde: s_i , $i \in \{1, 2\}$, y λ , Υ son parámetros de diseño. En [6] nuestro equipo presentó un análisis de estabilidad del algoritmo super twisting que resuelve el problema de seguimiento de trayectoria en condiciones de no sombra.

La implementación práctica del ST-SMC requiere que el modelo del sistema describa adecuadamente las dinámicas dominantes. Aunque el algoritmo es robusto frente a incertidumbres acotadas, su desempeño óptimo depende de la selección apropiada de las ganancias λ y Υ . La naturaleza de alta frecuencia de la señal de control demanda hardware con capacidad de procesamiento rápido y tasas de muestreo elevadas para evitar distorsión en el muestreo.

Optimización por Enjambre de Partículas PSO

La Optimización por Enjambre de Partículas (PSO) es un algoritmo metaheurístico de tipo poblacional que se fundamenta en el comportamiento colectivo de agentes individuales que colaboran para mejorar su desempeño tanto individual como grupal. En PSO, un conjunto (enjambre) de partículas explora el espacio de búsqueda, donde cada partícula simboliza una solución candidata, la cual puede ser una corriente, voltaje o ciclo de trabajo operativo del FV. Cada partícula i tiene una posición $\mathbf{x}_i$ (vector que codifica los valores de las variables de decisión) y una velocidad $\mathbf{v}_i$ que define dirección y magnitud de sus desplazamientos durante la búsqueda [36].

Las etapas principales utilizadas en el algoritmo original PSO [37] son:

1. Inicialización. Generar aleatoriamente un enjambre de partículas (P) con velocidades iniciales dentro de rangos definidos.

- Calcular la función de costo para cada partícula.
- Registrar la mejor posición personal (Pbest - mejor solución hallada por la partícula) y la mejor posición global (Gbest - mejor solución encontrada por cualquier partícula del enjambre).

2. Actualización de Velocidad. La nueva velocidad $\mathbf{v}_i^{t+1}$ se calcula mediante:

$$\mathbf{v}_i^{t+1} = \mathbf{v}_i^t + \alpha \epsilon_1 (\mathbf{Gbest} - \mathbf{x}_i^t) + \beta \epsilon_2 (\mathbf{Pbest} - \mathbf{x}_i^t) \quad (8)$$

donde:

- ϵ_1 y ϵ_2 son números aleatorios entre 0 y 1.
- α y β son parámetros de aprendizaje o constantes de aceleración que controlan la influencia de Pbest y Gbest en el movimiento de la partícula.

3. Actualización de Posición. La posición de cada partícula se ajusta sumando su nueva velocidad a su ubicación actual.

$$\mathbf{x}_i^{t+1} = \mathbf{x}_i^t + \mathbf{v}_i^{t+1} \quad (9)$$

4. Evaluación y Actualización de Pbest y Gbest. Se evalúa la función de costo en la nueva posición de cada partícula. Si supera su Pbest, este se actualiza. Si supera el Gbest, este se actualiza.

5. Iteración. El ciclo se repite hasta cumplir un criterio de terminación (ej. máximo de iteraciones o convergencia a una solución satisfactoria). La solución encontrada por PSO corresponde finalmente a la mejor posición global (Gbest).

Variantes del PSO

Nonlinear inertia weight variation for dynamic adaptation PSO (NLW_PSO)

Una de las mejoras más notables al algoritmo PSO estándar es la introducción de una constante de inercia w [39], que modifica la ecuación (8) de la siguiente manera:

$$\mathbf{v}_i^{t+1} = w \cdot \mathbf{v}_i^t + \alpha\epsilon_1(Pbest - \mathbf{x}_i^t) + \beta\epsilon_2(Gbest - \mathbf{x}_i^t) \quad (10)$$

Del Río [38] et al. proponen utilizar el algoritmo NLW_PSO para el MPPT en sistemas fotovoltaicos mostrado en la Fig. 4. Mediante las ecuaciones (10) y (9), determinan el ciclo de trabajo D óptimo de un convertidor Boost que permite alcanzar el MPP. Inicializan cinco partículas con valores aleatorios entre 0.1 y 0.9, y realizan un análisis de sensibilidad para optimizar los parámetros α , β y w , enfocado en maximizar la eficiencia y reducir el tiempo de convergencia. Obtienen como valores óptimos $\alpha = 0.2$, $\beta = 0.6$ y $w = 0.2$, logrando así un tiempo de convergencia de 15 s y una eficiencia del 10.89 % durante el transitorio.

Linear inertia weight for dynamic adaptation PSO (LW_PSO)

En [40], se utiliza una estrategia de inercia decreciente linealmente para mejorar el rendimiento del PSO en el seguimiento del punto de máxima potencia. La inercia w se actualiza en cada iteración según la siguiente ecuación:

$$w^t = w_{\max} - \left(\frac{w_{\max} - w_{\min}}{t_{\max}} \right) \cdot t \quad (11)$$

donde:

- w^t es el valor de la inercia en la iteración t .
- $w_{\max}$ y $w_{\min}$ son los valores máximo y mínimo de la inercia, respectivamente.
- $t_{\max}$ es el número máximo de iteraciones.
- t es el número de la iteración actual.

Esta estrategia permite que el algoritmo PSO comience con una mayor exploración (debido a un valor alto de w) y gradualmente se enfoque en la explotación (con un valor decreciente de w) a medida que avanza el proceso de optimización. Esto es particularmente útil en problemas con múltiples picos, como en el caso de sombreado parcial, donde es crucial evitar la convergencia a máximos locales.

El diagrama de flujo de la implementación del algoritmo LW_PSO [40], se muestra en la Fig. 5a. Utilizan 10 partículas donde cada una representa el V_{pv} al cual se explorará si se ha alcanzado el MPP. Con $t_{\max}=50$, $w_{\max}=0.9$, $w_{\min}=0.4$, $\alpha=2$ y $\beta=2$, encuentran que

Accelerated PSO (APSO)

El APSO es una variante mejorada del algoritmo clásico de optimización por enjambre de partículas (PSO). Su principal característica es la introducción de un mecanismo de aceleración que permite una convergencia más rápida hacia la solución óptima, especialmente en problemas complejos [41, 42]. A diferencia del PSO convencional, que utiliza tanto la mejor posición global (Gbest) como la mejor posición personal de cada partícula (Pbest), el APSO se basa únicamente en Gbest. La posición de las nuevas partículas no depende de la velocidad.






Figure 4. Flowchart of NLW_PSO, taken and modified from [38]



(a) LW_PSO flowchart, taken and modified from [40]
 cambiar las ecuaciones parecen que 9,10 y 11
Figure 5. Flowcharts



(b) SAPSO reference voltage flowchart, taken and modified from [24]

$$\mathbf{x}_i^{t+1} = (1 - \beta)\mathbf{x}_i^t + \beta G_{\text{best}} + \alpha \epsilon \quad (12)$$

donde $\mathbf{x}_i^{t+1}$ es la nueva posición de la partícula i , $\mathbf{x}_i^t$ es su posición actual, G_{best} es la mejor posición global encontrada hasta el momento, α es un coeficiente de amortiguamiento, β es un parámetro de que toma valores entre 0.1 a 0.7 y ϵ es un número aleatorio entre 0 y 1.

Simplified Accelerated PSO (SAPSO)

Para evitar el componente estocástico en la generación de nuevas soluciones Rajendran et al [24], eliminan el término aleatorio de la ecuación 12

$$\mathbf{x}_i^{t+1} = \mathbf{x}_i^t + \beta(G_{\text{best}} - \mathbf{x}_i^t) \quad (13)$$

Esta modificación reduce la complejidad computacional y mejora la eficiencia en microcontroladores de bajo costo, incorporando un paso variable que reemplaza la constante β por una función linealmente decreciente. Este ajuste dinámico adapta la velocidad de convergencia a las condiciones cambiantes del sistema fotovoltaico, mejorando el rendimiento en la búsqueda del GMPP bajo operación no óptima.

$$\beta = \beta_{\min} + \frac{t}{t_{\max}}(\beta_{\max} - \beta_{\min}) \quad (14)$$

donde t es el número de iteración, $t_{\max}$ es el número máximo de iteraciones y $\beta_{\min}$ y $\beta_{\max}$ son los valores mínimo y máximo de β . Al usar la función anterior, el valor de β varía de $\beta_{\min}$ a $\beta_{\max}$ conforme las iteraciones progresan de 1 a $t_{\max}$. El diagrama de flujo de la implementación del algoritmo SAPSO se muestra en 7b. La implementación del algoritmo SAPSO para encontrar el GMPP utilizando referencias de voltaje, se muestra en el diagrama de flujo de la figura 5b [24].

El algoritmo propuesto en este artículo se basa en el algoritmo SAPSO (Simplified Accelerated PSO), el cual ha sido modificado para optimizar el proceso de seguimiento del punto de máxima potencia (GMPP) en sistemas fotovoltaicos. En el SAPSO, las partículas utilizan un paso constante para actualizar su posición, lo que puede limitar la velocidad y precisión con la que se encuentra el GMPP en situaciones de variabilidad rápida de irradiancia o condiciones de sombreado parcial. Sin embargo, en este algoritmo, se introduce un paso variable que utiliza tanto valores positivos como negativos en las posiciones de las partículas. Esta estrategia tiene como objetivo mejorar la convergencia del algoritmo hacia el GMPP de manera más eficiente, permitiendo que el sistema se acerque más rápidamente a la mejor potencia posible, sin quedarse atrapado en puntos locales, ver 6. La clave de este enfoque radica en el uso de una referencia de corriente para el rastreo del GMPP, lo cual constituye una mejora respecto a los enfoques tradicionales que se basan principalmente en el ciclo de trabajo (duty cycle) o el voltaje de salida. La utilización de la corriente permite un rastreo más preciso y robusto, ya que la corriente es un parámetro directamente relacionado con la potencia generada por el panel fotovoltaico. Además, el algoritmo realiza una búsqueda a lo largo de todo el rango de corriente de cortocircuito I_{sc} , un ejemplo de cómo hace la búsqueda se puede observar en la figura 7b, lo que facilita una exploración más completa del espacio de operación del panel fotovoltaico y asegura que el algoritmo pueda adaptarse a cambios rápidos en las condiciones de irradiancia.

Otra característica importante de este algoritmo es que se entrega la referencia generada al controlador Super Twisting. Este controlador, conocido por su robustez y capacidad para manejar sistemas no lineales y perturbaciones, se adapta perfectamente al esquema de control propuesto, mejorando aún más el rendimiento del sistema fotovoltaico al asegurar que la potencia se mantenga cerca del GMPP en todo momento.

Además, para mejorar la estabilidad y evitar oscilaciones excesivas durante el proceso de rastreo, se incluyen tiempos de espera entre cada actualización de referencia. Estos tiempos de espera permiten que el panel fotovoltaico tenga el tiempo suficiente para detectar y adaptarse a los cambios en la referencia de corriente, lo cual es crucial para lograr un seguimiento preciso y sin fluctuaciones erráticas. Este mecanismo de espera también ayuda a reducir el desajuste entre la referencia de corriente y la respuesta real del sistema, lo cual puede ser un problema común en sistemas de rastreo de potencia que no consideran el comportamiento dinámico de los paneles solares.





Figure 6. Maquina de estados del algoritmo $MSAPSO_I$

Cabe destacar que algoritmos como el (PSO) y su variante adaptativa, utilizados en estrategias de referencia de voltaje, no incorporan estos tiempos de espera en su proceso de detección, como se evidencia en los diagramas de flujo de la Figura 5. Esta omisión puede llevar a una respuesta más rápida pero menos estable, ya que no permite que el sistema se estabilice adecuadamente antes de realizar una nueva actualización.


Cuando el tiempo de espera entre una detección y otra es demasiado corto, puede provocar oscilaciones alrededor del MPP, lo que resulta en una pérdida de energía y una reducción en la eficiencia del sistema. Por otro lado, un tiempo de espera excesivamente largo puede retrasar la convergencia al MPP, lo que también afecta negativamente la producción de energía. Por lo tanto, es crucial seleccionar un tiempo de espera adecuado que permita al controlador estabilizarse en el MPP sin incurrir en oscilaciones innecesarias o retrasos significativos.

Un tiempo de espera bien calibrado permite que el controlador alcance el MPP de manera rápida y estable, maximizando la energía generada por el panel fotovoltaico. Por el contrario, un tiempo de espera inadecuado puede resultar en una respuesta lenta o inestable, lo que reduce la eficiencia del sistema. Un tiempo de espera óptimo no solo mejora la eficiencia del sistema fotovoltaico, sino que también garantiza una operación estable y confiable bajo diversas condiciones ambientales. Por lo tanto, es esencial realizar un análisis cuidadoso y ajustar este parámetro según las características específicas del sistema y las condiciones de operación.

El conjunto de estas mejoras, como el uso del paso variable, la referencia de corriente, la búsqueda en el rango de I_{sc} y los tiempos de espera, permiten que el algoritmo alcance una convergencia más rápida y precisa al GMPP, incluso bajo condiciones de sombreado parcial o variabilidad rápida de irradiancia. Este enfoque no solo mejora el rendimiento del sistema fotovoltaico, sino que también reduce la complejidad computacional en comparación con otros algoritmos, lo que lo hace adecuado para implementaciones en sistemas con microcontroladores de bajo costo.



(a) Algoritmo APSO con referencia de voltaje



(b) Algoritmo MAPSO con referencia de corriente

Figure 7. Ejemplo de la búsqueda que realizan los algoritmos APSO y MAPSO para encontrar el GMPP, para este caso el GMPP ideal es 250.1W

Simulaciones Numéricas

En esta sección se presentan los resultados de simulaciones numéricas obtenidas al considerar el sistema fotovoltaico en lazo cerrado con la referencia generada con el algoritmo MAPSO y el controlador ST-SMC.

La tabla 2 muestra los valores numéricos de los parámetros del convertidor Boost. Estos valores se calcularon en función del voltaje y la corriente entregados por el módulo fotovoltaico y la carga aplicada al sistema; en este caso, se toma una carga resistiva.

Table 2. Parámetros del Convertidor Boost

Parameter	Value
Load resistance	12 Ω
Output capacitance	470 μf
Operation frequency PWM	45 KHz
Inductance	10 mH
Input capacitance	330 μf

Las ganancias λ , Υ del control de conmutación u_{st} definidas en la ecuación (7) se eligen como en [43]: $\lambda = 0, 1$, $\Upsilon = 0, 01$.

Para garantizar una simulación precisa y efectiva de los algoritmos MPPT, es esencial realizar un análisis exhaustivo del tiempo de espera entre ajustes. Este parámetro crítico influye directamente en la capacidad de los algoritmos para capturar las variaciones en el punto de máxima potencia (GMPP), equilibrando la estabilidad de las mediciones con la velocidad de convergencia. Un tiempo de espera demasiado breve puede introducir ruido en las lecturas de voltaje y corriente, mientras que uno excesivamente largo retrasaría la respuesta del sistema ante cambios en la irradiancia. A continuación, se detalla cómo se optimizó este intervalo para cada técnica y evaluando su impacto en el desempeño general.

Análisis de Tiempo de espera

Para que los algoritmos MPPT puedan detectar con precisión las señales de voltaje y corriente del panel fotovoltaico, es fundamental establecer un tiempo de espera adecuado entre cada ajuste en la búsqueda del punto de máxima potencia. En este análisis, se determina un tiempo de espera óptimo para cada algoritmo, tomando como referencia la potencia máxima ideal del sistema, que en este caso es de 250.1 W. El objetivo es encontrar un equilibrio entre la estabilidad de la medición y un tiempo de convergencia

reducido, asegurando que el algoritmo responda de manera eficiente a las variaciones en la irradiancia sin comprometer el seguimiento del punto de máxima potencia.

Para evaluar el impacto del tiempo de espera en el desempeño de los algoritmos MPPT, se realizaron múltiples simulaciones en las que se variaron los intervalos entre cada ajuste en la búsqueda del GMPP. En cada simulación, se registró la evolución de la potencia generada y el tiempo de convergencia del algoritmo, permitiendo analizar cómo estos parámetros cambian en función del tiempo de espera seleccionado. Este análisis general permite identificar tendencias comunes y establecer criterios para optimizar la respuesta de cada técnica.

En particular, para el algoritmo PSO, se presenta una gráfica 8 en la que se observa cómo la variación del tiempo de espera afecta la potencia alcanzada y el tiempo de convergencia. Los resultados muestran que tiempos de espera demasiado cortos pueden generar fluctuaciones en la potencia debido a mediciones inestables de voltaje y corriente, mientras que tiempos excesivamente largos pueden ralentizar la convergencia del algoritmo. A partir de este análisis, se determinó que el tiempo de espera óptimo para el PSO es de 0.005 segundos, lo que permite lograr una mejor potencia con una respuesta rápida y estable.




Figure 8. Análisis del tiempo de espera para el algoritmo PSO, en el cual se tiene una potencia teórica de 250 W

En la siguiente tabla 3 se muestran los tiempos de espera de cada uno de los algoritmos comparados en este artículo, lo que permite visualizar las diferencias en la optimización de este parámetro para cada técnica.

Cambios de irradiancia

Para evaluar el rendimiento de la estrategia MSAPSO con referencia de corriente y controlador por SMC-ST, se simularon variaciones abruptas de irradiancia en cuatro módulos del panel fotovoltaico. En particular, se consideraron cuatro escenarios diferentes de cambios en la irradiancia, los cuales se muestran en la Figura 9 y se describen a continuación. Estas simulaciones se diseñaron de manera similar a las

Algorithm	Waiting time(s)	Maximum Power (W)	Convergence time (s)
PSO	0.005	249.24	0.1276
APSO	0.002	249.32	0.173
$APSO_V$	0.002	248.4	0.065
$MSAPSO_I$	0.0005	250.1	0.12

Table 3. Tiempos de espera para los algoritmo PSO, APSO, $APSO_V$, $MSAPSO_I$, los cuales se analizaron con tomando una potencia teórica máxima de 250 W




Figure 9. Comparación del rendimiento del seguimiento de MPPT para 30 simulaciones consecutivas entre PSO, APSO(duty), $APSO_V$ y $MSAPSO_I$ para patrones de sombreado de: Caso 1 ($Irr1 = 800 \text{ W/m}^2$, $Irr2 = 800 \text{ W/m}^2$), Caso 2 ($Irr1 = 1000 \text{ W/m}^2$, $Irr2 = 652 \text{ W/m}^2$), Caso 3 ($Irr1 = 365 \text{ W/m}^2$, $Irr2 = 175 \text{ W/m}^2$), Caso 4 ($Irr1 = 175 \text{ W/m}^2$, $Irr2 = 1000 \text{ W/m}^2$, $Irr3 = 607 \text{ W/m}^2$, $Irr4 = 365 \text{ W/m}^2$).

reportadas en el artículo [22], con el objetivo de verificar que el algoritmo desarrollado sea capaz de generar una potencia comparable a la obtenida en dicho estudio, asegurando así la validez de los resultados y la efectividad del enfoque propuesto.

Caso 1 ($800 \frac{W}{m^2}$): En este caso, se simula un sistema fotovoltaico bajo condiciones óptimas de irradiancia, donde el panel fotovoltaico recibe una irradiancia de $800 \frac{W}{m^2}$. Esta es la condición ideal para la operación del sistema, con el objetivo de evaluar la capacidad de los distintos algoritmos PSO para encontrar y seguir el GMPP ideal, asegurando que el sistema esté operando a un mejor rendimiento.

Caso 2 En este caso se simula un módulo fotovoltaico que está sometido a irradiancias desiguales, en el cual se generan múltiples puntos de potencia. Este escenario permite estudiar cómo los diferentes algoritmos MPPT identifican y convergen hacia el GMPP, evitando quedarse atrapados en puntos locales. Para este caso, las irradiancias examinadas son: dos partes del panel a $1000 \frac{W}{m^2}$ y las otras 2 partes a $652 \frac{W}{m^2}$ en un lapso de 1 seg.; con una temperatura constante de 25°C .

Caso 3 En este caso, se simula un módulo fotovoltaico sometido a irradiancias mínimas, lo que genera múltiples puntos de potencia. Este escenario permite estudiar cómo los diferentes algoritmos MPPT identifican y convergen hacia el GMPP; para esta simulación, se consideran dos módulos del panel con irradiancias de $365 \frac{W}{m^2}$ y los otros

2 a $175 \frac{W}{m^2}$ en un lapso de 1 seg.; con una temperatura constante de $25^\circ C$, con el objetivo de analizar el impacto de estas condiciones y evaluar el desempeño del algoritmo en la localización precisa del GMPP.

Case 4 Para este caso se hará el análisis de un panel dividido en 4 módulos, recibiendo una irradiancia de $175 \frac{W}{m^2}$, $1000 \frac{W}{m^2}$, $607 \frac{W}{m^2}$ y $365 \frac{W}{m^2}$ respectivamente. El objetivo es proporcionar una visión más realista del desempeño del sistema fotovoltaico en escenarios dinámicos, simulando condiciones de irradiancia no homogénea que puedan reflejar situaciones de sombreado parcial o variabilidad en la irradiancia.

Los resultados obtenidos se describen a continuación:

En la gráfica de la figura 10, se observa que el algoritmo $MSAPSO_I$ presenta ventajas significativas en comparación con PSO y APSO. En términos de potencia máxima, $MSAPSO_I$ demostró un rendimiento superior, alcanzando un porcentaje de potencia más alto que los otros dos algoritmos. Como podemos ver en la figura 9, PSO mostró un tiempo de convergencia más rápido, $MSAPSO_I$ logró un equilibrio favorable entre el tiempo de convergencia y la calidad de la solución. Esto sugiere que $MSAPSO_I$ puede ofrecer soluciones más robustas sin comprometer significativamente el tiempo de procesamiento. Además, en cuanto a eficiencia, $MSAPSO_I$ se mostró competitivo, manteniendo un buen nivel de eficiencia mientras maximiza la potencia, lo que lo hace adecuado para aplicaciones que requieren un alto rendimiento. $MSAPSO_I$ destaca por su capacidad para maximizar la potencia y ofrecer soluciones robustas, en condiciones de sombreado uniforme.




Figure 10. Caso 1. Algoritmos PSO, APSO, $APSO_V$ y $MSAPSO_I$ con una irradiancia uniforme, en la cual se tiene una potencia teórica de 201.05W

Para el Caso 2, se observa en la figura 11 que el algoritmo $MSAPSO_I$ sigue destacando por su rendimiento superior en comparación con PSO y APSO. En términos de potencia máxima, $MSAPSO_I$ alcanzó un valor de 175.645 W, superando ligeramente los 175.611 W obtenidos por APSO y demostrando una clara ventaja sobre PSO. Este resultado refuerza la idea de que $MSAPSO_I$ es más efectivo en aplicaciones donde la sombra juega un factor crítico, ya que consigue aprovechar al máximo los recursos disponibles.

Además, como se ve en la figura 9 en lo que respecta al tiempo de convergencia se tiene una diferencia de 0.01s entre el $MSAPSO_I$ y el APSO con la diferencia de que el $MSAPSO_I$ mantiene un equilibrio óptimo entre la velocidad de convergencia y la calidad de la solución. Mientras que PSO puede ser más rápido en algunos casos,

$MSAPSO_I$ logra soluciones más robustas y precisas sin comprometer significativamente el tiempo de procesamiento.

En cuanto a la eficiencia, $MSAPSO_I$ se mantiene competitivo, mostrando un rendimiento similar al de APSO. Esto indica que, a pesar de su enfoque en maximizar la potencia, $MSAPSO_I$ no sacrifica la eficiencia energética.




Figure 11. Caso 2. Algoritmos PSO, APSO y $MSAPSO_I$ con una irradiancia variable media, en la cual se tiene una potencia teórica de 176.271W

Para el Caso 3 se observa en la figura 12 que el algoritmo $MSAPSO_I$ tiene un mejor rendimiento en comparación con PSO y APSO los cuales logran una potencia similar. Esto indica que en condiciones de sombreado abruptas como lo es este caso con irradiancias muy bajas, el $MSAPSO_I$ es más efectivo ya que ofrece un rendimiento más robusto.

Como se ve en la figura 9 con respecto al tiempo de convergencia, aunque PSO puede ser más rápido en algunos casos, $MSAPSO_I$ mantiene un equilibrio óptimo entre la velocidad de convergencia y la calidad de la solución. Esto significa que, aunque $MSAPSO_I$ puede tardar un poco más en converger, las soluciones que ofrece son más precisas. Respecto a la eficiencia, $MSAPSO_I$ demuestra un rendimiento competitivo en comparación con APSO. Aunque APSO puede tener una ligera ventaja en eficiencia en algunos casos, $MSAPSO_I$ no se queda atrás y logra mantener un buen nivel de eficiencia mientras maximiza la potencia.

En el análisis de la figura 13 correspondientes al Caso 4, se observa que el algoritmo $MSAPSO_I$ alcanza un valor de 77.8402 W, lo que representa un rendimiento significativamente mayor que los otros dos algoritmos. Este demuestra que aun en irradiancias complejas, el algoritmo $MSAPSO_I$ ofrece un rendimiento más robusto.

Como se ve en la figura 9 el tiempo de convergencia, el APSO logra una mejor tiempo con una diferencia con respecto al $MSAPSO_I$ de 0.018s. Mientras que PSO puede ser más rápido en algunos casos aunque con una potencia máxima promedio por debajo de los otros algoritmos.

Respecto a la eficiencia, el $MSAPSO_I$ se destaca, mostrando un rendimiento competitivo en comparación con APSO, con ello podemos analizar que el $MSAPSO_I$ ofrece un rendimiento superior aun en condiciones de sombra compleja.




Figure 12. Caso 3. Algoritmos PSO, APSO y $MSAPSO_I$ con una irradiancia mínima, en la cual se tiene una potencia teórica de 46.698W




Figure 13. Caso 4. Algoritmos PSO, APSO y $MSAPSO_I$ con una irradiancia variable, en la cual se tiene una potencia teórica de 78.84W

Cambios sombra parcial compleja

Se realizó un estudio detallado mediante simulaciones, para analizar el desempeño de los algoritmos ante cambios abruptos de sombras en el tiempo. Para ello, se han seleccionado los cuatro casos previamente analizados de forma independiente, los cuales se combinarán en pares con el objetivo de observar el funcionamiento de los algoritmos en escenarios complejos y variables. Las pruebas se realizarán en intervalos de 1 segundo, permitiendo una evaluación precisa de la respuesta de cada algoritmo frente a perturbaciones y transiciones bruscas. A través de este enfoque, se busca identificar características clave y comportamientos destacados que permitan optimizar la implementación de los algoritmos en espacios reales.

En la figura 14 se muestran las diferentes combinaciones que se realizaron y los

GMPPs que se deberían obtener en cada una de las combinaciones.

En la siguiente figura 14, se puede observar el desempeño de varios algoritmos, entre ellos el *MSAPSO_I*, el APSO, el *APSO_V* y el PSO.

Específicamente, se muestran los resultados en el intervalo de 1 a 2 segundos con el propósito de analizar el comportamiento de los algoritmos durante esta transición, ya que en la figura 9 ya se había descrito el comportamiento en el intervalo de 0 a 1 segundo, de cada caso.


El algoritmo *MSAPSO_I* destaca por su capacidad para mantener una alta eficiencia incluso ante variaciones bruscas en las condiciones de irradiancia. Por ejemplo, en la combinación 2, 4, 1,6, y 11, el *MSAPSO_I* logra valores de potencia (GMPPT) cercanos a los máximos teóricos, con una eficiencia superior al 99% en la mayoría de los casos. El algoritmo *APSO_V* tiene un buen desempeño cuando los valores de irradiancia son uniformes, alcanzando eficiencias del 99%. Sin embargo, cuando se presentan transiciones desde condiciones de baja potencia hacia valores significativamente mayores, el algoritmo no logra alcanzar el punto de máxima potencia global (GMPPT). Por otro lado, el algoritmo PSO muestra un comportamiento más variable. En algunos casos, como en la combinación 1, el PSO alcanza una eficiencia del 99%, lo que indica que puede lograr su objetivo en condiciones favorables. Sin embargo, en otras combinaciones, su eficiencia disminuye notablemente, con valores que rondan el 90% o menos. Esta inconsistencia puede atribuirse a la aleatoriedad del PSO, que, aunque efectivo en ciertos escenarios, tiende a perder eficiencia cuando los cambios son más abruptos o impredecibles.

Discusion

Como se analizó, cuando un panel fotovoltaico está sometido a condiciones de irradiancia desigual entre sus módulos, refleja de manera más realista las condiciones operativas de un sistema fotovoltaico en la vida real. Factores como sombras parciales, suciedad, nubosidad variable y diferencias en la orientación de los módulos pueden generar múltiples puntos de potencia máxima, lo que hace que la tarea del algoritmo MPPT sea más compleja.

Al replicar estas condiciones en simulaciones, se obtiene una evaluación más precisa del comportamiento de los algoritmos MPPT, su capacidad para localizar el GMPP y su eficiencia energética. En este estudio, para todos los algoritmos comparados, se ha implementado un tiempo de espera entre cada cambio en la búsqueda, lo que influye directamente en la capacidad del sistema para encontrar una mejor potencia. Sin embargo, hasta ahora, este aspecto no había sido analizado en la literatura, y no se había mostrado un estudio detallado sobre el impacto de trabajar con diferentes tiempos de espera en la búsqueda del punto de máxima potencia. Evaluar esta variable permite comprender su efecto en la estabilidad y eficiencia del sistema, así como optimizar su desempeño en condiciones dinámicas.

Las simulaciones muestran cómo algoritmos como el PSO logran llegar al GMPP en la mayoría de los casos, pero en ciertas situaciones, para alcanzar el punto de máxima potencia, generan oscilaciones bruscas que pueden afectar la estabilidad del sistema. En contraste, el APSO, al utilizar una señal de referencia de voltaje, busca alcanzar la potencia máxima de manera progresiva a través de las iteraciones. Aunque su tiempo de respuesta es rápido bajo condiciones de irradiancia uniforme, cuando se presentan obstáculos o cambios abruptos en la irradiancia, tiende a tomar más tiempo para encontrar una mejor potencia. En algunos casos específicos, se observa una marcada diferencia en el desempeño de los algoritmos cuando enfrentan cambios abruptos de sombreado, lo que resalta la importancia de evaluar su comportamiento en escenarios realistas y no solo en condiciones ideales.






Figure 14. Comparación de las combinaciones simuladas con los algoritmos $MSAPSO_I$, el $APSO$, $APSO_V$ y el PSO , alternando los 4 casos analizados en los incisos en la sección anterior.

Esto asegura que el sistema diseñado sea robusto y eficiente en escenarios cotidianos, donde las condiciones perfectas de irradiancia son la excepción más que la norma. Asimismo, al validar previamente el desempeño del algoritmo en diversas condiciones, se pueden realizar ajustes y optimizaciones antes de su implementación en hardware, reduciendo costos y tiempos de desarrollo.

Conclusiones

Este trabajo presenta una estrategia innovadora para el seguimiento del punto de máxima potencia (MPPT) en sistemas fotovoltaicos mediante un controlador de modos deslizantes de torsión superpuesta (ST-SMC). La principal contribución de este enfoque radica en la generación optimizada de señales de referencia para el controlador, combinando modelos de regresión lineal y múltiples con parámetros óptimos de operación del panel fotovoltaico. Estas señales permiten al controlador rastrear eficientemente el MPP incluso bajo variaciones abruptas de irradiancia y temperatura.

A través de simulaciones numéricas, se demuestra que el algoritmo ST-SMC con referencia de corriente generada por métodos metaheurísticos supera en rendimiento a enfoques como PSO, APSO y algoritmos híbridos basados en redes neuronales artificiales (ANN) con controladores PID. En particular, el ST-SMC logra una convergencia más rápida al MPP y minimiza oscilaciones y sobretiros, lo que mejora la eficiencia en la extracción de energía. Además, se destaca que el tiempo de retardo es un factor clave en el desempeño del algoritmo, ya que una reducción en este parámetro permite una respuesta más ágil ante cambios de irradiancia. Asimismo, se observa que los algoritmos comparados presentan un desplazamiento uniforme en su trayectoria hacia el MPP, lo que contrasta con la capacidad del ST-SMC para adaptarse de manera más precisa y dinámica a variaciones en las condiciones ambientales.

Una ventaja clave del método propuesto es que no requiere sensores de temperatura, lo que reduce costos y simplifica su implementación. No obstante, su principal desafío radica en su aplicación en condiciones de sombreado parcial, donde la irradiancia no es uniforme en todo el panel. Como trabajo futuro, se sugiere la integración de métodos híbridos basados en metaheurísticas para abordar esta limitación.

References

- [1] Ahmed Refaat, Abd-Elwahab Khalifa, Mohamed Mohamed Elsakka, Yasser Elhenawy, Ahmed Kalas, and Medhat Hegazy Elfar. A novel metaheuristic MPPT technique based on enhanced autonomous group Particle Swarm Optimization Algorithm to track the GMPP under partial shading conditions - Experimental validation. *Energy Conversion and Management*, 287:117124, 2023.
- [2] Hadeed Ahmed Sher, Ali Faisal Murtaza, Abdullah Noman, Khaled E Addoweesh, Kamal Al-Haddad, and Marcello Chiaberge. A new sensorless hybrid mppt algorithm based on fractional short-circuit current measurement and p&o mppt. *IEEE Transactions on sustainable energy*, 6(4):1426–1434, 2015.
- [3] Harsha Choutapalli, K.R. Bharath, and P. Kanakasabapathy. A review on advanced mppt methods for spv system under partial shaded conditions. In *2018 International Conference on Control, Power, Communication and Computing Technologies (ICCPCT)*, pages 305–310, 2018.
- [4] Dezso Sera, Laszlo Mathe, Tamas Kerekes, Sergiu Viorel Spataru, and Remus Teodorescu. On the perturb-and-observe and incremental conductance mppt methods for pv systems. *IEEE Journal of Photovoltaics*, 3(3):1070–1078, 2013.

- [5] Rozana Alik and Awang Jusoh. An enhanced p&o checking algorithm mppt for high tracking efficiency of partially shaded pv module. *Solar Energy*, 163:570–580, 2018.
- [6] Itzel Contreras Carmona, Belem Saldivar, Otniel Portillo-Rodríguez, Víctor Manuel Ramírez Rivera, Leopoldo Gil Antonio, and Juan Manuel Jacinto-Villegas. A novel strategy for the mppt in a photovoltaic system via sliding modes control. *Plos one*, 19(12):e0311831, 2024.
- [7] Md Tahmid Hussain, Adil Sarwar, Mohd Tariq, Shabana Urooj, Amal BaQais, and Md. Alamgir Hossain. An evaluation of ann algorithm performance for mppt energy harvesting in solar pv systems. *Sustainability*, 15(14), 2023.
- [8] Mehmet Yılmaz and Muhammed Fatih Çorapsız. A robust mppt method based on optimizable gaussian process regression and high order sliding mode control for solar systems under partial shading conditions. *Renewable Energy*, 239:122339, 2025.
- [9] Md Tahmid Hussain, Adil Sarwar, Mohd Tariq, Shabana Urooj, Amal BaQais, and Md. Alamgir Hossain. An evaluation of ann algorithm performance for mppt energy harvesting in solar pv systems. *Sustainability*, 15(14), 2023.
- [10] Ahmed Fathy Abouzeid, Hadeer Eleraky, Ahmed Kalas, Rawya Rizk, Mohamed Mohamed Elsakka, and Ahmed Refaat. Experimental validation of a low-cost maximum power point tracking technique based on artificial neural network for photovoltaic systems. *Scientific Reports*, 14(1):18280, 2024.
- [11] Rajib Baran Roy, Md Rokonzaman, Nowshad Amin, Mahmuda Khatun Mishu, Sanath Alahakoon, Saifur Rahman, Nadarajah Mithulananthan, Kazi Sajedur Rahman, Mohammad Shakeri, and Jagadeesh Pasupuleti. A comparative performance analysis of ann algorithms for mppt energy harvesting in solar pv system. *IEEE Access*, 9:102137–102152, 2021.
- [12] Umair Younas, Ahmet Afsin Kulaksiz, and Zunaib Ali. Deep learning stack lstm based mppt control of dual stage 100 kw grid-tied solar pv system. *IEEE Access*, 12:77555–77574, 2024.
- [13] Zain Ahmad Khan, Laiq Khan, Saghir Ahmad, Sidra Mumtaz, Muhammad Jafar, and Qudrat Khan. Rbf neural network based backstepping terminal sliding mode mppt control technique for pv system. *Plos one*, 16(4):e0249705, 2021.
- [14] Sarra Zaidi, Bouziane Meliani, Riyadh Bouddou, Souheyb Mohammed Belhadj, and Nasreddine Bouchikhi. Comparative study of different types of DC/DC converters for PV systems using RBF neural network-based MPPT algorithm. *Journal of Renewable Energies*, pages 13–31, October 2024.
- [15] F. Belhachat, C. Larbes, and R. Bennia. Empowering MPPT Efficiency in Partial Shading with Machine Learning Driven Metaheuristic Strategies: Recent Developments. In Mustapha Hatti, editor, *Smart Computing and Control Renewable Energy Systems*, pages 594–612, Cham, 2025. Springer Nature Switzerland.
- [16] Samuel Figueiredo, Ranoyca Nayana Alencar Leão e Silva, et al. Hybrid mppt technique pso-p&o applied to photovoltaic systems under uniform and partial shading conditions. *IEEE Latin America Transactions*, 19(10):1610–1617, 2021.

- [17] Slimane Hadji, Jean-Paul Gaubert, and Fateh Krim. Real-time genetic algorithms-based mppt: Study and comparison (theoretical an experimental) with conventional methods. *Energies*, 11(2), 2018.
- [18] Jubaer Ahmed and Zainal Salam. A Maximum Power Point Tracking (MPPT) for PV system using Cuckoo Search with partial shading capability. *Applied Energy*, 119:118–130, April 2014.
- [19] Saad Motahhir, Aboubakr El Hammoumi, and Abdelaziz El Ghzizal. The most used mppt algorithms: Review and the suitable low-cost embedded board for each algorithm. *Journal of cleaner production*, 246:118983, 2020.
- [20] Majd Ghazi Batarseh and Muhy Eddin Za’ter. Hybrid maximum power point tracking techniques: A comparative survey, suggested classification and uninvestigated combinations. *Solar Energy*, 169:535–555, 2018.
- [21] Othman M. Hussein Anssari, Mohammadali Badamchizadeh, and Sehraneh Ghaemi. Designing of a pso-based adaptive smc with a multilevel inverter for mppt of pv systems under rapidly changing weather conditions. *IEEE Access*, 12:41421–41435, 2024.
- [22] Mohamed A. Hendy, Mohamed A. Nayel, Jose Rodriguez, and Mohamed Abdelrahem. Enhanced maximum power point tracking using modified pso hybrid with mpc under partial shading conditions. *IEEE Access*, 12:145318–145330, 2024.
- [23] Mustafa Sacid Endiz, Göksel Gökkuş, Atıl Emre Coşgun, and Hasan Demir. A review of traditional and advanced mppt approaches for pv systems under uniformly insolation and partially shaded conditions. *Applied Sciences*, 15(3), 2025.
- [24] Subha Rajendran and Himavathi Srinivasan. Simplified accelerated particle swarm optimisation algorithm for efficient maximum power point tracking in partially shaded photovoltaic systems. *IET Renewable Power Generation*, 10(9):1340–1347, 2016.
- [25] EE Granda-Gutiérrez, OA Orta, JC Díaz-Guillén, MA Jimenez, M Osorio, and MA González. Modelado y simulación de celdas y paneles solares. In *Congreso internacional de ingeniería electronica*, volume 35, pages 17–22, 2013.
- [26] Djamila Rekioua and Ernest Matagne. *Optimization of photovoltaic power systems: modelization, simulation and control*. Springer Science & Business Media, 2012.
- [27] Leopoldo Gil-Antonio, Belem Saldivar, Otniel Portillo-Rodríguez, Juan Carlos Ávila-Vilchis, Pánfilo Raymundo Martínez-Rodríguez, and Rigoberto Martínez-Méndez. Flatness-based control for the maximum power point tracking in a photovoltaic system. *Energies*, 12(10):1843, 2019.
- [28] Arno Smets, Klaus Jäger, Olindo Isabella, René Van Swaaij, and Miro Zeman. *Solar Energy: The physics and engineering of photovoltaic conversion, technologies and systems*. Bloomsbury Publishing, 2016.
- [29] Robert W Erickson. Dc–dc power converters. *Wiley encyclopedia of electrical and electronics engineering*, pages 2–4, 2001.
- [30] Hebertt Sira-Ramírez and Ramón Silva-Ortigoza. *Control Design Techniques in Power Electronics Devices*. Power Systems. Springer London, 2006.

- [31] Shahzad Ahmed, Hafiz Mian Muhammad Adil, Iftikhar Ahmad, Muhammad Kashif Azeem, Zil e Huma, and Safdar Abbas Khan. Supertwisting sliding mode algorithm based nonlinear mppt control for a solar pv system with artificial neural networks based reference generation. *Energies*, 13(14):3695, 2020.
- [32] Zicheng Li, Mengxiong Ruan, Hou-Neng Wang, and Sai Zhang. Chaos control of boost converter based on super-twisting sliding mode control. In *2019 Chinese Control And Decision Conference (CCDC)*, pages 188–193. IEEE, 2019.
- [33] Leopoldo Gil Antonio. *Control de Convertidores para aplicaciones Fotovoltaicas*. Doctoral dissertation, Facultad de Ingeniería, Universidad Autónoma del Estado de México, Toluca, México, December 2018.
- [34] Ameni Kchaou, A Naamane, Y Koubaa, and Nacer M'sirdi. Second order sliding mode-based mppt control for photovoltaic applications. *Solar Energy*, 155:758–769, 2017.
- [35] Mohamed Derbeli, Oscar Barambones, Jose Antonio Ramos-Hernanz, and Lassaad Sbita. Real-time implementation of a super twisting algorithm for pem fuel cell power system. *Energies*, 12(9):1594, 2019.
- [36] El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. Wiley, 1 edition, June 2009.
- [37] Riccardo Poli, James Kennedy, and Tim Blackwell. Particle swarm optimization: An overview. *Swarm intelligence*, 1(1):33–57, 2007.
- [38] Asier del Rio, Oscar Barambones, Jokin Uralde, Eneko Artetxe, and Isidro Calvo. Particle Swarm Optimization-Based Control for Maximum Power Point Tracking Implemented in a Real Time Photovoltaic System. *Information*, 14(10):556, October 2023. Number: 10 Publisher: Multidisciplinary Digital Publishing Institute.
- [39] A. Chatterjee and P. Siarry. Nonlinear inertia weight variation for dynamic adaptation in particle swarm optimization. *Computers & Operations Research*, 33(3):859–871, March 2006.
- [40] Mohammad Sarvi, Saeedeh Ahmadi, and Shirzad Abdi. A pso-based maximum power point tracking for photovoltaic systems under environmental and partially shaded conditions. *Progress in Photovoltaics: Research and Applications*, 23(2):201–214, 2015.
- [41] Xin-She Yang, Suash Deb, and Simon Fong. Accelerated Particle Swarm Optimization and Support Vector Machine for Business Optimization and Applications. In Simon Fong, editor, *Networked Digital Technologies*, pages 53–66, Berlin, Heidelberg, 2011. Springer.
- [42] Xin-She Yang. Chapter 7 - particle swarm optimization. In Xin-She Yang, editor, *Nature-Inspired Optimization Algorithms*, pages 99–110. Elsevier, Oxford, 2014.
- [43] Amar Bouafassa, Lazhar Rahmani, and Saad Mekhilef. Design and real time implementation of single phase boost power factor correction converter. *ISA transactions*, 55:267–274, 2015.